

Estadística Aplicada

Equipo Editorial, Wulfrano Gómez Gallardo

2026-09-04

Índice general

1. ANTECEDENTES	5
1.1. Muestra y población	5
1.2. Distribuciones muestrales	5
1.3. Intervalos de confianza	5
1.4. Pruebas de hipótesis	5
2. Muestreo	7
2.1. Muestreo aleatorio y restricto	7
2.2. Muestreo estratificado	7
2.3. Muestreo por conglomerados	7
2.4. Muestreo secuencial	7
3. Análisis de Regresión: De la Inferencia a la Predicción con R	9
3.1. Fundamentos del Análisis de Regresión	10
3.1.1. Introducción al Análisis de Regresión	10
3.1.2. El Modelo de Regresión Lineal Simple	11
3.1.3. El Modelo de Regresión Lineal Múltiple	13
3.2. Supuestos del MCRL y Estimación MCO	14
3.2.1. Supuestos del Modelo Clásico de Regresión Lineal (MCRL)	14
3.2.2. Estimación por Mínimos Cuadrados Ordinarios (MCO)	16
3.3. Inferencia Estadística en Regresión	18
3.3.1. Distribución de los estimadores	18
3.3.2. Pruebas de hipótesis	18

3.3.3. Intervalos de confianza y predicción	18
3.4. Medidas de Bondad de Ajuste	18
3.4.1. Coeficiente de determinación R^2	18
3.4.2. R^2 ajustado	18
3.4.3. Limitaciones del R^2	18
3.5. Diagnóstico del Modelo: Análisis de R	18
3.5.1. Tipos de Residuos	18
3.5.2. Gráficos de diagnósticos esenciales	18
3.5.3. Detección de observaciones influyentes	18
3.6. Violaciones de los Supuestos y Remedios	18
3.6.1. Heteroscedasticidad	18
3.6.2. Multicolinealidad	18
3.6.3. Autocorrelación (Series de Tiempo)	18
3.7. Selección de Variables y Extensiones del Modelo	18
3.7.1. Selección de Variables y Modelos	18
3.7.2. Extensiones del Modelo Lineal	18
3.8. Evaluación Predictiva y Validación	18
3.8.1. División entrenamiento-prueba	18
3.8.2. Métricas de evaluación predictiva	18
3.8.3. Validación cruzada k-fold	18
3.9. Modelos GLM y Técnicas de Regularización	18
3.9.1. Introducción a Modelos Lineales Generalizados (GLM) . .	18
3.9.2. Técnicas de Regularización: Ridge y LASSO	18
3.10. Práctica y Material Complementario	18
3.10.1. Análisis de Regresión en la Práctica: Flujo de Trabajo Completo	18
3.10.2. Buenas Prácticas y Lista de Verificación	18
3.10.3. Ejercicios Propuestos y Actividades Prácticas	18
3.10.4. Recursos Adicionales y Referencias	18
3.10.5. Resumen y Conclusiones	18

4. Diseño y Análisis de Experimentos: Fundamentos, Modelación e Interpretación	19
4.1. Fundamentos del experimento y análisis de variación	21
4.1.1. El experimento y sus fines	21
4.1.2. Elementos del experimento: factores, niveles, tratamientos, variable respuesta	21
4.1.3. Diseño del experimento	21
4.1.4. Número de ensayos	21
4.1.5. Análisis de variaciones	21
4.1.6. Análisis de resultados	21
4.2. Análisis de varianza e interpretación de resultados	21
4.2.1. ANOVA de un factor	21
4.2.2. ANOVA de dos factores	21
4.2.3. Comparaciones múltiples	21
4.3. Diseño experimental multifactorial y control de variabilidad . . .	21
4.3.1. Bloques experimentales	21
4.3.2. Cuadrados latinos	21
4.3.3. Cuadrados grecolatinos	21
4.3.4. Diseño factorial 2^k	21
4.3.5. Interpretación de interacción	21
5. Inferencia Estadística No Paramétrica: Métodos y Aplicaciones	23
5.1. Introducción a la inferencia no paramétrica	25
5.1.1. Diferencia entre métodos paramétricos y no paramétricos.	25
5.1.2. Ventajas y limitaciones.	25
5.1.3. Situaciones en las que se recomienda su uso.	25
5.2. Pruebas de hipótesis para una muestra	25
5.2.1. Prueba de los signos.	25
5.2.2. Prueba de Wilcoxon para una muestra.	25
5.3. Pruebas de hipótesis para dos muestras	25
5.3.1. Prueba de Mann-Whitney U (Wilcoxon de rangos sumados).	25
5.3.2. Prueba de los signos para pares apareados.	25

5.3.3. Prueba de Wilcoxon para pares apareados.	25
5.4. Extensión a más de dos muestras	25
5.4.1. Prueba de Kruskal-Wallis.	25
5.4.2. Prueba de Friedman para diseños con bloques.	25
5.5. Medidas de asociación no paramétricas	25
5.5.1. Coeficiente de correlación de rangos de Spearman.	25
5.5.2. Tau de Kendall.	25
5.6. Aplicaciones prácticas en ingeniería	25
5.6.1. Control de calidad y confiabilidad.	25
5.6.2. Comparación de procesos o materiales.	25
5.6.3. Ejemplos con datos reales (tiempos de respuesta, resistencia de materiales, rendimiento de equipos).	25
5.7. Implementación computacional	25
5.7.1. Ejemplos de aplicación en software estadístico (R, Python, SPSS y/o Excel).	25
5.8. Conclusiones y recomendaciones	25
5.8.1. Relevancia en la práctica profesional.	25
5.8.2. Comparación con métodos paramétricos.	25

Capítulo 1

ANTECEDENTES

Objetivos **

- 1.1. Muestra y población
- 1.2. Distribuciones muestrales
- 1.3. Intervalos de confianza
- 1.4. Pruebas de hipótesis

Capítulo 2

Muestreo

Objetivo * *

2.1. Muestreo aleatorio y restricto

2.2. Muestreo estratificado

2.3. Muestreo por conglomerados

2.4. Muestreo secuencial

Capítulo 3

Análisis de Regresión: De la Inferencia a la Predicción con R

Objetivo del capítulo: Proporcionar una guía integral y práctica para comprender, estimar, diagnosticar e interpretar modelos de regresión lineal, diferenciando entre objetivos de **inferencia estadística** y **predicción**, con implementaciones reproducibles en R que siguen las mejores prácticas de ciencia de datos moderna.

Al completar este capítulo podrás:

- Diferenciar entre correlación y regresión, y explicar el rol fundamental del término de error
- Estimar e interpretar modelos de regresión lineal simple y múltiple usando `lm()` y el ecosistema **tidyverse**
- Evaluar críticamente los supuestos del Modelo Clásico de Regresión Lineal (MCRL)
- Realizar inferencia estadística robusta (pruebas t , F , intervalos de confianza y predicción)
- Diagnosticar problemas comunes (heteroscedasticidad, autocorrelación, multicolinealidad, observaciones atípicas)
- Aplicar transformaciones, manejar variables categóricas y seleccionar modelos apropiados
- Implementar estrategias de validación y evaluación predictiva fuera de muestra

Prerrequisitos: Álgebra lineal básica, cálculo diferencial, probabilidad y estadística inferencial, manejo intermedio de R y RStudio.

3.1. Fundamentos del Análisis de Regresión

3.1.1. Introducción al Análisis de Regresión

3.1.1.1. ¿Qué es el análisis de regresión?

El análisis de regresión es una técnica estadística que estudia la **dependencia** de una variable respuesta Y (también llamada variable dependiente o endógena) respecto de una o más variables explicativas X_i (variables independientes, predictoras o exógenas). Su objetivo principal es modelar y cuantificar la relación para:

1. **Estimar** el valor promedio condicional $E(Y|X)$
2. **Predecir** valores futuros de Y dado X
3. **Inferir** sobre la naturaleza y magnitud de las relaciones
4. **Controlar** por el efecto de variables confusoras

Como señalan Harrell Jr (2015) y Gelman et al. (2020), la distinción entre estos objetivos es crucial para la especificación del modelo y la interpretación de resultados.

3.1.1.2. Regresión versus correlación

Es fundamental distinguir estos conceptos:


- **Correlación:** Mide la fuerza y dirección de una asociación **lineal simétrica** entre dos variables. El coeficiente de correlación de Pearson r_{XY} trata ambas variables por igual.
- **Regresión:** Modela una dependencia **asimétrica** de Y respecto de X , donde Y es la variable “respuesta” y X la variable “explicativa”. Busca estimar $E(Y|X) = f(X)$.

3.1.1.3. Tipología de variables

Siguiendo la taxonomía de Bruce et al. (2020), clasificamos las variables según su naturaleza:

Variables respuesta (Y): - **Continuas:** Pueden tomar cualquier valor en un intervalo (ej: peso, ingreso) - **Discretas:** Valores enteros contables (ej: número de hijos) - **Catégoricas:** Nominales u ordinales (tratadas en modelos lineales generalizados)

Variables explicativas (X_i): - **Cuantitativas:** Continuas o discretas con significado numérico - **Cualitativas:** Categóricas que requieren codificación (variables dummy)



3.1.1.4. El término de perturbación ε

El término de error ε es central en el análisis de regresión y captura:

1. **Variables omitidas:** Factores relevantes no incluidos en el modelo
2. **Error de medición:** Imprecisiones en la medición de variables
3. **Forma funcional incorrecta:** Relaciones no lineales aproximadas linealmente
4. **Variabilidad inherente:** Componente aleatorio genuino del fenómeno

La especificación correcta de ε es crucial para la validez de la inferencia estadística (Gujarati and Porter 2009).

3.1.2. El Modelo de Regresión Lineal Simple

3.1.2.1. Formulación del modelo

El modelo de regresión lineal simple se expresa como:

Tabla 3.1: Resultados del modelo de regresión simple

term	estimate	std.error	statistic	p.value	conf.low	conf.high
(Intercept)	49055.079	1002.826	48.917	0	47077.488	51032.669
experiencia	1323.586	62.713	21.105	0	1199.914	1447.258

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, 2, \dots, n$$

donde: - Y_i : valor observado de la variable respuesta para la observación i - X_i : valor de la variable explicativa para la observación i - β_0 : intercepto (ordenada al origen) - β_1 : pendiente (efecto marginal de X sobre Y) - ε_i : término de error para la observación i


3.1.2.2. Función de regresión poblacional (FRP) vs. muestral (FRM)

- **FRP:** $E(Y|X) = \beta_0 + \beta_1 X$ (parámetros poblacionales desconocidos)
- **FRM:** $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$ (estimadores muestrales)

3.1.2.3. Interpretación de parámetros

- β_0 : Valor esperado de Y cuando $X = 0$ (si tiene sentido sustantivo)
- β_1 : Cambio esperado en Y por cada unidad adicional de X

```
## `geom_smooth()` using formula = 'y ~ x'
```



Interpretación práctica: Por cada año adicional de experiencia, el salario esperado aumenta en aproximadamente 1324 dólares, manteniendo todo lo demás constante.

3.1.3. El Modelo de Regresión Lineal Múltiple

3.1.3.1. Generalización matemática

El modelo de regresión múltiple extiende el caso simple a k variables explicativas:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \varepsilon_i$$

En notación matricial:

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon$$

donde: - $\mathbf{Y}$ es un vector $n \times 1$ de observaciones - $\mathbf{X}$ es una matriz $n \times (k + 1)$ de diseño - β es un vector $(k + 1) \times 1$ de parámetros - ε es un vector $n \times 1$ de errores

3.1.3.2. Interpretación de coeficientes parciales (ceteris paribus)

En regresión múltiple, β_j representa el **efecto marginal** de X_j sobre Y , manteniendo **constantes** todas las demás variables explicativas. Esto es crucial para el control de variables confusoras (Wooldridge 2015).

Tabla 3.2: Modelo de regresión múltiple: Determinantes del salario

term	estimate	std.error	statistic	p.value	conf.low	conf.high
(Intercept)	20692.466	3405.062	6.077	0.000	13976.989	27407.943
edad	997.822	156.220	6.387	0.000	689.725	1305.920
experiencia	297.930	164.206	1.814	0.071	-25.917	621.778
educacionSecundaria	7319.872	833.352	8.784	0.000	5676.331	8963.412
educacionUniversidad	14576.768	918.700	15.867	0.000	12764.903	16388.632

Tabla 3.3: Comparación de modelos: Simple vs. Múltiple

model	r.squared	adj.r.squared	AIC	BIC	p.value
simple	0.6923	0.6907	4163.086	4172.980	0
multiple	0.8825	0.8801	3976.526	3996.316	0

3.1.3.3. Linealidad en parámetros

El modelo es lineal en los **parámetros** β_j , no necesariamente en las **variables**. Podemos incluir: - Transformaciones: $\log(X)$, $\sqrt{X}$, X^2 - Interacciones: $X_1 \times X_2$ - Variables dummy para categorías

Interpretación de educación: Controlando por edad y experiencia, tener educación universitaria se asocia con un incremento promedio de 7320 dólares en el salario comparado con educación primaria.

3.2. Supuestos del MCRL y Estimación MCO

3.2.1. Supuestos del Modelo Clásico de Regresión Lineal (MCRL)


3.2.1.1. Supuestos fundamentales

1. **Linealidad en parámetros:** El modelo está correctamente especificado
2. **Exogeneidad estricta:** $E(\varepsilon_i|X_i) = 0$ para todo i
3. **Homoscedasticidad:** $\text{Var}(\varepsilon_i|X_i) = \sigma^2$ (varianza constante)
4. **No autocorrelación:** $\text{Cov}(\varepsilon_i, \varepsilon_j|X) = 0$ para $i \neq j$
5. **No multicolinealidad perfecta:** $\text{rank}(\mathbf{X}) = k + 1$
6. **Normalidad** (para muestras pequeñas): $\varepsilon_i \sim N(0, \sigma^2)$


3.2.1.2. Implicaciones de violaciones

Supuesto violado	Efecto en MCO	Inferencia afectada
Exogeneidad	Sesgo e inconsistencia	Sí
Homoscedasticidad	Ineficiencia	Errores estándar
No autocorrelación	Ineficiencia	Errores estándar
Multicolinealidad	Alta varianza	Significancia
Normalidad	-	Pruebas t/F (muestras pequeñas)

3.2.1.3. Verificación práctica de supuestos



```
## `geom_smooth()` using method = 'loess' and formula = 'y ~ x'
```



Prueba de Breusch-Pagan (Homoscedasticidad):

```
##
## studentized Breusch-Pagan test
##
## data: modelo_multiple
## BP = 8.8749, df = 4, p-value = 0.0643
```

##

Prueba de Shapiro-Wilk (Normalidad):

```
##
## Shapiro-Wilk normality test
##
## data: residuals(modelo_multiple)
## W = 0.99557, p-value = 0.8302
```

Tabla 3.4: Verificación: MCO manual vs. función lm()

	Coficiente	MCO_manual	lm_function	Diferencia
(Intercept)	(Intercept)	20692.4663	20692.4663	0
edad	edad	997.8225	997.8225	0
experiencia	experiencia	297.9304	297.9304	0
educacionSecundaria	educacionSecundaria	7319.8716	7319.8716	0
educacionUniversidad	educacionUniversidad	14576.7678	14576.7678	0

3.2.2. Estimación por Mínimos Cuadrados Ordinarios (MCO)

3.2.2.1. Derivación del estimador

El estimador MCO minimiza la suma de cuadrados de residuos:

$$\min_{\beta} \sum_{i=1}^n (Y_i - \mathbf{x}'_i \beta)^2$$

La solución analítica es:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}$$

3.2.2.2. Propiedades estadísticas

Bajo los supuestos del MCRL: - **Insesgadez:** $E[\hat{\beta}|\mathbf{X}] = \beta$ - **Eficiencia:** BLUE (Best Linear Unbiased Estimator) por el teorema de Gauss-Markov - **Consistencia:** $\text{plim}_{n \rightarrow \infty} \hat{\beta} = \beta$ - **Normalidad asintótica:** $\hat{\beta} \xrightarrow{d} N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$

3.2.2.3. Estimación de σ^2

El estimador insesgado de la varianza del error es:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{\varepsilon}_i^2}{n - k - 1} = \frac{\text{SCR}}{n - k - 1}$$

donde SCR es la suma de cuadrados de los residuos y $n - k - 1$ son los grados de libertad.

3.3. Inferencia Estadística en Regresión

3.3.1. Distribución de los estimadores

3.3.2. Pruebas de hipótesis

3.3.3. Intervalos de confianza y predicción

3.4. Medidas de Bondad de Ajuste

3.4.1. Coeficiente de determinación R^2

3.4.2. R^2 ajustado

3.4.3. Limitaciones del R^2

3.5. Diagnóstico del Modelo: Análisis de R

3.5.1. Tipos de Residuos

3.5.2. Gráficos de diagnósticos esenciales

3.5.3. Detección de observaciones influyentes

3.6. Violaciones de los Supuestos y Remedios

3.6.1. Heteroscedasticidad

3.6.2. Multicolinealidad

3.6.3. Autocorrelación (Series de Tiempo)

3.7. Selección de Variables y Extensiones del Modelo

3.7.1. Selección de Variables y Modelos

3.7.2. Extensiones del Modelo Lineal

3.8. Evaluación Predictiva y Validación

3.8.1. División entrenamiento-prueba

3.8.2. Métricas de evaluación predictiva

3.8.3. Validación cruzada k-fold

3.9. Modelos GLM y Técnicas de Regularización

Capítulo 4

Diseño y Análisis de Experimentos: Fundamentos, Modelación e Interpretación

Objetivo: *Que el alumnado sea capaz de comprender, diseñar y analizar experimentos, interpretando la variabilidad de los datos y el efecto de uno o múltiples factores mediante modelos de análisis de varianza y diseños experimentales, apoyándose en herramientas visuales y de simulación para la toma de decisiones.*

Contenido

4.1. Fundamentos del experimento y análisis de variación

4.1.1. El experimento y sus fines

4.1.2. Elementos del experimento: factores, niveles, tratamientos, variable respuesta

4.1.3. Diseño del experimento

4.1.4. Número de ensayos

4.1.5. Análisis de variaciones

4.1.6. Análisis de resultados

4.2. Análisis de varianza e interpretación de resultados

4.2.1. ANOVA de un factor

4.2.1.1. Idea de comparación de tratamientos

4.2.1.2. Descomposición de la variación

4.2.1.3. Interpretación del estadístico F

4.2.2. ANOVA de dos factores

4.2.2.1. Dos criterios de variación

4.2.2.2. Interpretación básica

4.2.3. Comparaciones múltiples

4.2.3.1. ¿Qué tratamientos son diferentes?

4.2.3.2. Interpretación

4.3. Diseño experimental multifactorial y control de variabilidad

4.3.1. Bloques experimentales

4.3.1.1. Control de fuentes de variación

4.3.1.2. Concepto de bloques completos e incompletos

4.3.2. Cuadrados latinos

4.3.2.1. Control de dos fuentes de variación

za ya que consideramos que requiere base fuerte en regresión, aumenta carga matemática y no es esencial para el objetivo del curso.

Capítulo 5

Inferencia Estadística No Paramétrica: Métodos y Aplicaciones

Objetivo: *El objetivo de este capítulo es familiarizar a los estudiantes de ingeniería con la inferencia no paramétrica. Este enfoque consta de una colección de procedimientos que les permitirá realizar análisis estadístico sin la necesidad de suponer distribuciones de probabilidad específicas para los datos. En particular, se busca que los alumnos aprendan a realizar pruebas no paramétricas en situaciones reales donde las técnicas paramétricas no sean factibles. Asimismo, se espera que adquieran la capacidad de interpretar los resultados de manera crítica y los relacionen con su campo profesional.*

Contenido

5.1. Introducción a la inferencia no paramétrica

5.1.1. Diferencia entre métodos paramétricos y no paramétricos.

5.1.2. Ventajas y limitaciones.

5.1.3. Situaciones en las que se recomienda su uso.

5.2. Pruebas de hipótesis para una muestra

5.2.1. Prueba de los signos.

5.2.2. Prueba de Wilcoxon para una muestra.

5.3. Pruebas de hipótesis para dos muestras

5.3.1. Prueba de Mann-Whitney U (Wilcoxon de rangos sumados).

5.3.2. Prueba de los signos para pares apareados.

5.3.3. Prueba de Wilcoxon para pares apareados.

5.4. Extensión a más de dos muestras

5.4.1. Prueba de Kruskal-Wallis.

5.4.2. Prueba de Friedman para diseños con bloques.

5.5. Medidas de asociación no paramétricas

5.5.1. Coeficiente de correlación de rangos de Spearman.

5.5.2. Tau de Kendall.

5.6. Aplicaciones prácticas en ingeniería

5.6.1. Control de calidad y confiabilidad.

5.6.2. Comparación de procesos o materiales.

5.6.3. Ejemplos con datos reales (tiempos de respuesta, resistencia de materiales, rendimiento de equipos).

5.7. Implementación computacional

5.7.1. Ejemplos de aplicación en software estadístico (R, Python, SPSS y/o Excel).

Media.

Gelman, Andrew, Jennifer Hill, and Aki Vehtari. 2020. *Regression and Other Stories*. Cambridge University Press.

Gujarati, Damodar N, and Dawn C Porter. 2009. *Basic Econometrics*. 5th ed. McGraw-Hill/Irwin.

Harrell Jr, Frank E. 2015. *Regression Modeling Strategies: With Applications to Linear Models, Logistic and Ordinal Regression, and Survival Analysis*. 2nd ed. Springer.

Wooldridge, Jeffrey M. 2015. *Introductory Econometrics: A Modern Approach*. 6th ed. Cengage Learning.