

Estadística Aplicada

Equipo Editorial, Wulfrano Gómez Gallardo

2026-09-23

Índice general

1. MUESTRA Y PROBLACIÓN	5
1.1. POBLACIÓN	5
1.2. Muestreo	6
1.3. ESTIMADORES	7
2. DISTRIBUCIONES MUESTRALES	9
2.1. Teorema del Límite Central	11
2.2. ESTIMACIÓN PUNTUAL	11
3. INTERVALOS DE CONFIANZA	13
4. PRUEBAS DE HIPÓTESIS	17
5. Muestreo	21
5.1. Muestreo aleatorio y restringido	21
5.2. Muestreo estractificado	21
5.3. Muestreo por conglomerados	21
5.4. Muestreo secuencial	21
6. Análisis de Regresión: De la Inferencia a la Predicción con R	23
6.1. Fundamentos del Análisis de Regresión	24
6.1.1. Introducción al Análisis de Regresión	24
6.1.2. El Modelo de Regresión Lineal Simple	25
6.1.3. El Modelo de Regresión Lineal Múltiple	27

6.2. Supuestos del MCRL y Estimación MCO	28
6.2.1. Supuestos del Modelo Clásico de Regresión Lineal (MCRL)	28
6.2.2. Estimación por Mínimos Cuadrados Ordinarios (MCO)	30
6.3. Inferencia Estadística en Regresión	31
6.3.1. Distribución de los estimadores	31
6.3.2. Pruebas de hipótesis	31
6.3.3. Intervalos de confianza y predicción	32
6.4. Medidas de Bondad de Ajuste	33
6.4.1. Coeficiente de determinación R^2	33
6.4.2. R^2 ajustado	34
6.4.3. Limitaciones del R^2	34
6.5. Diagnóstico del Modelo: Análisis de R	34
6.5.1. Tipos de Residuos	34
6.5.2. Gráficos de diagnósticos esenciales	37
6.5.3. Detección de observaciones influyentes	39
6.6. Violaciones de los Supuestos y Remedios	39
6.6.1. Heteroscedasticidad	39
6.6.2. Multicolinealidad	40
6.6.3. Autocorrelación (Series de Tiempo)	41
6.7. Selección de Variables y Extensiones del Modelo	42
6.7.1. Selección de Variables y Modelos	42
6.7.2. Extensiones del Modelo Lineal	44
6.8. Evaluación Predictiva y Validación	46
6.8.1. División entrenamiento-prueba	46
6.8.2. Métricas de evaluación predictiva	47
6.8.3. Validación cruzada k-fold	48
6.9. Modelos GLM y Técnicas de Regularización	49
6.9.1. Introducción a Modelos Lineales Generalizados (GLM)	49
6.9.2. Técnicas de Regularización: Ridge y LASSO	51
6.10. Práctica y Material Complementario	52

6.10.1. Análisis de Regresión en la Práctica: Flujo de Trabajo Completo	52
6.10.2. Buenas Prácticas y Lista de Verificación	54
6.10.3. Ejercicios Propuestos y Actividades Prácticas	55
6.10.4. Recursos Adicionales y Referencias	55
6.10.5. Resumen y Conclusiones	56
7. Diseño y Análisis de Experimentos: Fundamentos, Modelación e Interpretación	59
7.1. Fundamentos del experimento y análisis de variación	61
7.1.1. El experimento y sus fines	61
7.1.2. Elementos del experimento: factores, niveles, tratamientos, variable respuesta	61
7.1.3. Diseño del experimento	61
7.1.4. Número de ensayos	61
7.1.5. Análisis de variaciones	61
7.1.6. Análisis de resultados	61
7.2. Análisis de varianza e interpretación de resultados	61
7.2.1. ANOVA de un factor	61
7.2.2. ANOVA de dos factores	61
7.2.3. Comparaciones múltiples	61
7.3. Diseño experimental multifactorial y control de variabilidad . . .	61
7.3.1. Bloques experimentales	61
7.3.2. Cuadrados latinos	61
7.3.3. Cuadrados grecolatinos	61
7.3.4. Diseño factorial 2^k	61
7.3.5. Interpretación de interacción	61
8. Inferencia Estadística No Paramétrica: Métodos y Aplicaciones	63
8.1. Introducción a la inferencia no paramétrica	65
8.1.1. Diferencia entre métodos paramétricos y no paramétricos.	65
8.1.2. Ventajas y limitaciones.	65
8.1.3. Situaciones en las que se recomienda su uso.	65

8.2. Pruebas de hipótesis para una muestra	65
8.2.1. Prueba de los signos.	65
8.2.2. Prueba de Wilcoxon para una muestra.	65
8.3. Pruebas de hipótesis para dos muestras	65
8.3.1. Prueba de Mann-Whitney U (Wilcoxon de rangos sumados).	65
8.3.2. Prueba de los signos para pares apareados.	65
8.3.3. Prueba de Wilcoxon para pares apareados.	65
8.4. Extensión a más de dos muestras	65
8.4.1. Prueba de Kruskal-Wallis.	65
8.4.2. Prueba de Friedman para diseños con bloques.	65
8.5. Medidas de asociación no paramétricas	65
8.5.1. Coeficiente de correlación de rangos de Spearman.	65
8.5.2. Tau de Kendall.	65
8.6. Aplicaciones prácticas en ingeniería	65
8.6.1. Control de calidad y confiabilidad.	65
8.6.2. Comparación de procesos o materiales.	65
8.6.3. Ejemplos con datos reales (tiempos de respuesta, resistencia de materiales, rendimiento de equipos).	65
8.7. Implementación computacional	65
8.7.1. Ejemplos de aplicación en software estadístico (R, Python, SPSS y/o Excel).	65
8.8. Conclusiones y recomendaciones	65
8.8.1. Relevancia en la práctica profesional.	65
8.8.2. Comparación con métodos paramétricos.	65

Capítulo 1

MUESTRA Y POBLACIÓN

1.1. POBLACIÓN

Una población, en estadística, es un conjunto de elementos que comparten una característica en común de interés para un investigador.

Como ejemplos podemos mencionar el interés de un investigador sobre el uso de celulares entre estudiantes de secundaria en México. En este caso la población está integrada por todos los mexicanos que se encuentren actualmente inscritos en una institución educativa, pública o privada a nivel secundaria. También podría ser del interés de un investigador ciertas especies y su capacidad de reproducción. Por ejemplo, las plagas que afectan las grandes ciudades como son las ratas. En este caso se podría establecer la cantidad de roedores que se concentran en una ciudad, para establecer como se reproducen o migran a estas grandes ciudades como Nueva York.

Las poblaciones pueden ser finitas o infinitas, de ellas se pueden medir características cuantitativas o cualitativas. Como ejemplo de poblaciones infinitas podemos mencionar el lanzamiento de una moneda un número infinito de veces, los números que se encuentran entre cero y uno, que pueden ser seleccionados al azar, entre otros. Mientras que las poblaciones finitas pueden estar representadas por ciudadanos en un país, número de especies en una región, entre otros. Las características cuantitativas que se pueden medir de estas poblaciones pueden ser edad, estaturas, pesos, entre otros. Mientras que las características cuantitativas como color de ojos, color de la piel, entre otros.

Las características cualitativas siempre deben ser cuantificadas de forma cuantitativa para fines estadísticos, a estas variables se les conoce como factores. Por

ejemplo el nivel de satisfacción de por u servicio recibido, los cuales son representados por figuras para hacer que el usuario pueda responde de la forma más objetiva y de manera sencilla, como se muestra en la figura 1¹



Figura 1.1: Encuesta de satisfacción

Debido a que las poblaciones pueden ser demasiado grandes para censarlas o el tiempo es limitado para realizar el censo, o no se cuentan con los recursos económicos necesarios, es que se deben realizar muestreos.

1.2. Muestreo

Una muestra es un subconjunto de la población que se selecciona de forma aleatoria, representativa e insesgada.

¿Qué significa esto?

- Aleatorio: Los elementos se seleccionan sin un orden específico. Esto es, no se sabe qué elemento será seleccionado. Generalmente se generan números aleatorios o se seleccionan los elementos de una tómbola.
- Representativo: En este caso se espera que los elementos de la población queden representados en la muestra. suponga que una población de 1,000 personas, con un 20 % de mujeres y un 80 % de hombres, la muestra debería tener al menos un número suficientes de representates de hombres y mujeres. Por ejemplo, si una muestra de 100 elementos de esta población que se toma de manera aleatoria, podría conducir a que todos los elementos seleccionados fueran hombres y ninguna mujer, esta muestra no sería representativa.
- Insesgado: Se espera que la muestra sea aleatoria, lo que evitaría algún criterio de selección e los elementos de la muestra por parte del investigador. Por ejemplo: Suponga que una acreditadora desea seleccionar a diez estudiantes de manera aleatoria de un grupo de matemáticas, para

¹ Fuente: Extraído de https://www.magnific.com/es/vector-gratis/medidor-satisfaccion-emoji-pequeno_44156211.htm#fromView=keyword&page=1&position=0&uuid=484b5e55-bf2d-4120-b59f-55c1c2d67403&track=ais_hybrid&query=Caritas+satisfaccion

aplicarles una prueba y evaluar el desempeño del profesor. Suponga también que el profesor será recompensado si los estudiantes seleccionados aleatoriamente obtiene buenos resultados, en caso contrario, su contrato será rescindido. El profesor podría verse tentado a seleccionar solo a los alumnos con mejor promedio para este fin, lo que provocaría un sesgo al seleccionar dicha muestra.

1.3. ESTIMADORES

Debido a que las poblaciones son demasiado grandes para censarlas o el tiempo para realizar el censo es limitado, así como los recursos financieros y humanos, es que nos vemos en la necesidad de realizar muestreo. Es necesario realizar estimaciones de los parámetros poblacionales que deseamos conocer. Esto es, si el objetivo fuera calcular la estatura promedio de los estudiantes de la facultad de ingeniería y sólo tuviéramos un par de días para hacerlo, a través de una muestra se estiman los parámetros poblacionales, en este caso la media. Entonces se dice que la media muestral $\bar{x}$ estima al parámetro poblacional μ .

La diferencia en el cálculo de la media de una muestra y de una poblacional es la siguiente

Media muestral

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1.1)$$

en donde

$\bar{x}$: Es la media muestral.

n : es el tamaño de la muestra y representa la probabilidad de seleccionar un elemento. En este caso todos los elementos de la muestra son equiprobables. Esto es, tiene la misma probabilidad de ser seleccionados.

x_i : es el elemento i -ésimo, seleccionado de la población de forma aleatoria.

Media poblacional

En el caso de una variable aleatoria² discreta

$$\mu = \sum_{i=1}^N x_i p(x_i) \quad (1.2)$$

en donde:

μ : es la media poblacional.

²Una variable aleatoria para este fin se considera un evento asociado a una probabilidad

N : es el tamaño de la población.

$p(x_i)$: es la medida de la probabilidad del evento x_i .

x_i : es el i -ésimo elemento de la población.

En este caso se dice que el estadístico $\bar{x}$ estima al parámetro μ . Esto es

$\bar{X}$ estima a μ

La siguiente aplicación ejemplifica esto

Es claro que el valor del estadístico no corresponderá exactamente al valor del parámetro, debido a que el primero se calcula con un subconjunto de los elementos de la población.

¿Por qué entonces podemos confiar en un estadístico de una muestra para estimar un parámetro poblacional?

Capítulo 2

DISTRIBUCIONES MUESTRALES

Una distribución de muestras, es el resultado de tomar la combinación de un tamaño n de elementos de una población de tamaño N generando K combinaciones y calculando $\bar{x}_k$ medias muestrales, las cuales resultan ser variables aleatorias (v.a.). Esto es, si se seleccionan diferentes muestras, del mismo tamaño n de forma aleatoria, de una población, cada una de ellas tendría un valor diferente y la probabilidad de que alguna de ellas acierte al valor del parámetro poblacional μ es casi seguramente cero.

En forma matemática se tiene

$$C(N, n) = \binom{N}{n} = \frac{N!}{n!(N-n)!} = K \quad (2.1)$$

en donde

K : es el número de combinaciones de tamaño n tomadas de N .

En este caso la varianza de las medias de las muestras se calcula como

$$\sigma_{\bar{x}}^2 = \frac{\sum_{i=1}^K (\bar{X}_i - \bar{\bar{X}})^2}{K} \quad (2.2)$$

donde

$$\bar{\bar{X}} = \frac{\sum_{i=1}^K \bar{X}_i}{K} \quad (2.3)$$

$\bar{\bar{X}}$: media de las medias.

y la i -ésima media de las muestras, con un tamaño de muestra n es

$$\bar{X}_i = \frac{\sum_{j=1}^n X_j}{n} \quad (2.4)$$

En este caso el error estándar se obtiene al sacar la raíz cuadrada de la ecuación (2.2)

$$\sigma_{\bar{x}} = \sqrt{\sigma_x^2} \quad (2.5)$$

Como se puede observar, el cálculo del error estándar por este procedimiento no es recomendable ya que existen más combinaciones $\mathbf{K}$ que el número de elementos de la población $\mathbf{N}$. lo que lo hace poco práctico o inservible si se desea calcular. Esto es, es más fácil censar a la población, que tomar todas las combinaciones de las muestras de tamaño n para calcular el error estándar.

En este caso, considere las variables aleatorias

$$X_1, X_2, \dots, X_n \quad (2.6)$$

En donde

$$E[X_i] = \mu \quad (2.7)$$

y su varianza es

$$Var[X_i] = \sigma^2 \quad (2.8)$$

De la ecuación (2.4), la media muestral es

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} \quad (2.9)$$

y su varianza

$$Var[\bar{X}] = Var\left[\frac{X_1 + X_2 + \dots + X_n}{n}\right] \quad (2.10)$$

en donde

$$Var[\bar{X}] = \frac{Var[X_1] + Var[X_2] + \dots + Var[X_n]}{n^2} \quad (2.11)$$

de la ecuación (2.10) se tiene

$$Var[\bar{X}] = \frac{n\sigma^2}{n^2} \quad (2.12)$$

donde

$$Var[\bar{X}] = \frac{\sigma^2}{n} \quad (2.13)$$

y finalmente el error estándar es

$$\sigma_{\bar{x}} = \sqrt{\frac{\sigma^2}{n}} = \frac{\sigma}{\sqrt{n}} \quad (2.14)$$

2.1. Teorema del Límite Central

Sean $X_1, X_2, \dots, X_n$ una muestra de tamaño n de una población de tamaño N con media μ y varianza finita σ^2 , de esta población se obtienen k combinaciones de tamaño n , que generan $\bar{X}_k$ medias muestrales, estas últimas tienden a distribuirse de forma asintótica a la normal con media $\bar{\bar{X}} = \mu$ y error estándar $\sigma_{\bar{x}}$, el cual disminuye conforme el tamaño de la muestra aumenta, no importando la distribución de probabilidad de la que provengan las variables aleatorias de las muestras tomadas.

La figura 2 ejemplifica esto.

2.2. ESTIMACIÓN PUNTUAL

Como se puede observar los valores de $\bar{X}_i$ se distribuyen de forma gaussiana alrededor de $\bar{\bar{X}} = \mu$ y a medida que el tamaño de la muestra aumenta, el error estándar disminuye y los valores se encuentran más cerca del parámetro poblacional μ . Sin embargo, la probabilidad de que alguna $\bar{X}_i$ sea igual al parámetro desconocido μ es casi seguramente de cero, aún si el valor fuera igual o casi igual al parámetro no lo sabría, por eso la estimación puntual del parámetro no es recomendable, por lo que es necesario utilizar un intervalo donde se pueda establecer, con un error específico y una probabilidad, que se encontrará el parámetro real pero desconocido.




Figura 2.1: Teorema del Límite Central

Capítulo 3

INTERVALOS DE CONFIANZA

Un intervalo de confianza se establece como la probabilidad de que el parámetro desconocido μ se encuentre en un rango de valores, a dicha probabilidad asociada se le conoce como **coeficiente de confianza** $cc = 1 - \alpha$ y se calcula al restar a uno el nivel de significancia α . Tanto el coeficiente de confianza como el nivel de significancia tienen un rango de valores aceptados. Por ejemplo, el cc se acepta se encuentre $90\% \leq cc < 100\%$, mientras que $0\% < \alpha \leq 10\%$.

En este caso, si a la media poblacional se le colocan un par de brazos, uno a la izquierda y el otro a la derecha, con tamaño $2\sigma_{\bar{x}}$ se tendrían el 95.5 % de las $\bar{x}_i$ y solo el 4.5 % no los contendría. Sin embargo, como no se conoce el valor de μ se deben colocar estos brazos en lo que sí se conoce $\bar{X}_i$ y suponer que existe un 95.5 % de probabilidad de que este contenga a la media poblacional.

La razón por la que se usa la variable aleatoria z_i , que corresponde a una variable aleatoria con distribución gaussina, específicamente la normal estándar con media $\mu_z = 0$ y desviación estándar $\sigma_z = 1$, es por que las distribuciones muestrales, como se ha establecido en el Teorema del Límite Central, se distribuyen de forma normal.

El tamaño del brazo que se le coloca a la media muestral se le conoce como error y se calcula con

$$E = z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \quad (3.1)$$

En donde

E : Error de muestreo

$z_{\frac{\alpha}{2}}$: Es el valor de la distribución z que nos indica el número de desviaciones estándar a la izquierda y a la derecha en el que se concentran el 95.5 % de los elementos en una distribución normal estándar.

σ : Es la desviación estándar poblacional.

n : Es el tamaño de la muestra.

En este caso se suma y se resta este error E a la $\bar{X}_i$ para obtener los límites de confianza inferior y superior.

$$IC = \bar{X}_i \pm E. \quad (3.2)$$

En donde

IC : Intervalo de confianza

E : Error de muestreo

Esto es

$$LI = \bar{X}_i - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \quad (3.3)$$

y

$$LS = \bar{X}_i + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \quad (3.4)$$

En donde

LS : Límite superior.

LI : Límite inferior.

La siguiente aplicación ejemplifica el uso de dichos intervalos

COLOCAR LIGA DE APP

Un ejemplo del uso de los intervalos de confianza se presenta a continuación.

Ejemplo 1:

Suponga que se desea estimar la estatura promedio de los estudiantes de la Facultad de Ingeniería, se sabe que la desviación estándar poblacional es de 9 cm. Una muestra de 31 alumnos reporta la siguiente media muestral $\bar{x} = 167$ cm. Suponga que se desea estimar a la media poblacional con una probabilidad del 95.5 %.

Solución

En este caso, el error de muestreo es de $E = \pm 3.24$ cm. El límite inferior $LI = 63.76$ y el límite superior $LS = 70.24$. Lo que significa que existe un 95.5 % de

probabilidad de que la media poblacional de la estatura se encuentre entre estos valores. Es obvio que si se aumenta el tamaño de la muestra se incrementa el Error disminuye. Esto se verá en el ejemplo 2.

Ejemplo 2:

Suponga que en el ejemplo 1, el tamaño de la muestra es de 60 elementos. ¿Cuál sería el error de muestreo E ?

Solución

El nuevo error de muestreo con una muestra de 62 es de $E = \pm 2.29$ cm, el cual es menor al error $E = \pm 3.24$ cm con una muestra de 31 estudiantes. Como puede observarse, a pesar de que el tamaño de la muestra se duplicó, el error de muestreo no se redujo a la mitad.

Este tema será profundizado con mayor detalle en el siguiente capítulo, en donde se abordarán temas relacionados con el muestreo aleatorio irrestricto. También se analizará la situación cuando σ no sea conocida y qué pasa cuando la población que se analiza, el interés del investigador se centre en las proporciones.

En otras ocasiones el interés del investigador es el de encontrar el valor del parámetro que describe a una población, o la probabilidad de que este sea mayor o menor que un valor predeterminado, para esto se emplea una prueba de hipótesis.

Capítulo 4

PRUEBAS DE HIPÓTESIS

Una hipótesis, desde el punto de vista de la estadística, es una aseveración que se hace sobre un parámetro poblacional. Por ejemplo:

- Establecer que la estatura promedio los estudiantes de la facultad de ingeniería es de 170 cm.
- El gasto promedio de las familias que pertenecen a la clase media en México es de \$10,000 MXN.
- La cantidad de tiempo que un adolescente invierte en redes sociales al día es de 8 h.

Así como estos, existen una enorme cantidad de aseveraciones que puede hacer un investigador acerca de una población. Adicionalmente, como cualquier hipótesis en una investigación, esta tiene que ser comprobada. En este caso, la forma en que un investigador puede comprobar su aseveración es a través de una muestra y la extracción de un estadístico de prueba, que deber ser probada para demostrar que la diferencia no es estadísticamente significativa y que su aseveración es correcta.

Por ejemplo, regresando a nuestra población (estudiantes de la Facultad de Ingeniería), si se desea verificar que el gasto promedio semanal de los estudiantes es de \$500.00 MXN. En este caso $\mu_0 = \$500.00$ MXN, donde μ_0 es la aseveración que se hace sobre el parámetro μ la media poblacional, real pero desconocida, y la forma de establecer si la diferencia es estadísticamente significativa es a través de una muestra de tamaño n lo suficientemente grande para calcular un $\bar{X}_i$ y a través de la siguiente expresión (con σ conocida)


$$z_i = \frac{\mu_0 - \bar{X}_i}{\sigma/\sqrt{n}} \quad (4.1)$$

El valor de z se compara con una $z_{\alpha/2}$, debido a que es una prueba de dos colas, ya que cualquier valor que se aleje de \$500.00 MXN por debajo o de \$500.00 por arriba, lo suficiente, rechazará nuestra aseveración. Esto significa que si $-z_{\alpha/2} \leq z_i \leq z_{\alpha/2}$ no habrá evidencia para rechazar la hipótesis de que la media de los gastos promedios de los estudiantes en una semana sea diferente de \$500.00 MXN.

Normalmente, cuando se establecen pruebas de hipótesis estadísticas se pueden establecer las siguientes hipótesis nulas e hipótesis alternativas:

$$\begin{array}{lll} H_0 : \mu = \mu_0 & H_0 : \mu \leq \mu_0 & H_0 : \mu \geq \mu_0 \\ H_0 : \mu \neq \mu_0 & H_0 : \mu > \mu_0 & H_0 : \mu < \mu_0 \end{array}$$

Zonas de Aceptación y Rechazo en Pruebas de Hipótesis



Como se puede observar en las figuras, al área sombreada en los extremos, a esta probabilidad se le conoce como α o *nivel de significancia* y el resto del área se le conoce como *coeficiente de confianza* $cc = 1 - \alpha$. Estas áreas presentan las zonas de aceptación cc y rechazo α .

Ejemplo 3:

Suponga que se toma una muestra de 30 estudiantes de la Facultad de Ingeniería y se desea probar que la estatura promedio es de 172 cm, la muestra arrojó un valor promedio de 168 cm. Con un nivel de significancia α del 5% y una varianza conocida y finita $\sigma = 5$ cm ¿Existe suficiente evidencia para rechazar la hipótesis nula?

$$H_0 : \mu = 172 \text{ cm}$$

$$H_A : \mu \neq 172 \text{ cm}$$

El estadístico de prueba es

$$z_i = \frac{\mu_0 - \bar{x}}{\sigma/\sqrt{n}} \quad (4.2)$$

Al comparar la $z_{\alpha/2} = \pm 1.959964$ con el valor de $z_i = 4.3817805$ del estadístico de prueba, se observa que se encuentra en la zona de rechazo, por lo que existe suficiente evidencia para rechazar H_0 y se puede decir que no existe evidencia para afirmar que los estudiantes midan 172 cm.

Una forma alternativa de resolver el problema es con el valor p , o el “*p-value*”. En este caso se calcula la probabilidad del valor de z_i con la distribución normal estándar y se compara con el valor $\alpha/2$, si el valor de $\alpha/2 = .05/2 = .025 \geq p\text{-value}$ existe suficiente evidencia para rechazar H_0 , en caso contrario, cuando $\alpha/2 = .05/2 = .025 < p\text{-value}$, no existe suficiente evidencia para rechazar H_0 . Esto se puede comprobar con el siguiente análisis.

Como el valor de $\alpha/2 = 2,5\% \geq 0.0005885670\%$ existe suficiente evidencia para decir que los estudiantes no miden 172 cm.

Para concluir con este breve repaso se resolverán los siguientes ejemplos:

Ejemplo 3.

Su ponga que se desea estimar si la población mide más de 172 cm con la misma muestra.

$$H_0 :$$

Capítulo 5

Muestreo

Objetivo * *

5.1. Muestreo aleatorio y restricto

5.2. Muestreo estratificado

5.3. Muestreo por conglomerados

5.4. Muestreo secuencial

Capítulo 6

Análisis de Regresión: De la Inferencia a la Predicción con R

Objetivo del capítulo: Proporcionar una guía integral y práctica para comprender, estimar, diagnosticar e interpretar modelos de regresión lineal, diferenciando entre objetivos de **inferencia estadística** y **predicción**, con implementaciones reproducibles en R que siguen las mejores prácticas de ciencia de datos moderna.

Al completar este capítulo podrás:

- Diferenciar entre correlación y regresión, y explicar el rol fundamental del término de error
- Estimar e interpretar modelos de regresión lineal simple y múltiple usando `lm()` y el ecosistema `tidyverse`
- Evaluar críticamente los supuestos del Modelo Clásico de Regresión Lineal (MCRL)
- Realizar inferencia estadística robusta (pruebas t , F , intervalos de confianza y predicción)
- Diagnosticar problemas comunes (heteroscedasticidad, autocorrelación, multicolinealidad, observaciones atípicas)
- Aplicar transformaciones, manejar variables categóricas y seleccionar modelos apropiados
- Implementar estrategias de validación y evaluación predictiva fuera de muestra

Prerrequisitos: Álgebra lineal básica, cálculo diferencial, probabilidad y estadística inferencial, manejo intermedio de R y RStudio.

6.1. Fundamentos del Análisis de Regresión

6.1.1. Introducción al Análisis de Regresión

6.1.1.1. ¿Qué es el análisis de regresión?

El análisis de regresión es una técnica estadística que estudia la **dependencia** de una variable respuesta Y (también llamada variable dependiente o endógena) respecto de una o más variables explicativas X_i (variables independientes, predictoras o exógenas). Su objetivo principal es modelar y cuantificar la relación para:

1. **Estimar** el valor promedio condicional $E(Y|X)$
2. **Predecir** valores futuros de Y dado X
3. **Inferir** sobre la naturaleza y magnitud de las relaciones
4. **Controlar** por el efecto de variables confusoras

Como señalan Harrell Jr (2015) y Gelman et al. (2020), la distinción entre estos objetivos es crucial para la especificación del modelo y la interpretación de resultados.

6.1.1.2. Regresión versus correlación

Es fundamental distinguir estos conceptos:


- **Correlación:** Mide la fuerza y dirección de una asociación **lineal simétrica** entre dos variables. El coeficiente de correlación de Pearson r_{XY} trata ambas variables por igual.
- **Regresión:** Modela una dependencia **asimétrica** de Y respecto de X , donde Y es la variable “respuesta” y X la variable “explicativa”. Busca estimar $E(Y|X) = f(X)$.

6.1.1.3. Tipología de variables

Siguiendo la taxonomía de Bruce et al. (2020), clasificamos las variables según su naturaleza:

Variables respuesta (Y): - **Continuas:** Pueden tomar cualquier valor en un intervalo (ej: peso, ingreso) - **Discretas:** Valores enteros contables (ej: número de hijos) - **Catégoricas:** Nominales u ordinales (tratadas en modelos lineales generalizados)

Variables explicativas (X_i): - **Cuantitativas:** Continuas o discretas con significado numérico - **Cualitativas:** Categóricas que requieren codificación (variables dummy)



6.1.1.4. El término de perturbación ε

El término de error ε es central en el análisis de regresión y captura:

1. **Variables omitidas:** Factores relevantes no incluidos en el modelo
2. **Error de medición:** Imprecisiones en la medición de variables
3. **Forma funcional incorrecta:** Relaciones no lineales aproximadas linealmente
4. **Variabilidad inherente:** Componente aleatorio genuino del fenómeno

La especificación correcta de ε es crucial para la validez de la inferencia estadística (Gujarati and Porter 2009).

6.1.2. El Modelo de Regresión Lineal Simple

6.1.2.1. Formulación del modelo

El modelo de regresión lineal simple se expresa como:

Tabla 6.1: Resultados del modelo de regresión simple

term	estimate	std.error	statistic	p.value	conf.low	conf.high
(Intercept)	49055.079	1002.826	48.917	0	47077.488	51032.669
experiencia	1323.586	62.713	21.105	0	1199.914	1447.258

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, 2, \dots, n \quad (6.1)$$

donde: - Y_i : valor observado de la variable respuesta para la observación i - X_i : valor de la variable explicativa para la observación i - β_0 : intercepto (ordenada al origen) - β_1 : pendiente (efecto marginal de X sobre Y) - ε_i : término de error para la observación i


6.1.2.2. Función de regresión poblacional (FRP) vs. muestral (FRM)

- **FRP:** $E(Y|X) = \beta_0 + \beta_1 X$ (parámetros poblacionales desconocidos)
- **FRM:** $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$ (estimadores muestrales)

6.1.2.3. Interpretación de parámetros

- β_0 : Valor esperado de Y cuando $X = 0$ (si tiene sentido sustantivo)
- β_1 : Cambio esperado en Y por cada unidad adicional de X

```
## `geom_smooth()` using formula = 'y ~ x'
```



Interpretación práctica: Por cada año adicional de experiencia, el salario esperado aumenta en aproximadamente 1324 dólares, manteniendo todo lo demás constante.

6.1.3. El Modelo de Regresión Lineal Múltiple

6.1.3.1. Generalización matemática

El modelo de regresión múltiple extiende el caso simple a k variables explicativas:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \varepsilon_i \quad (6.2)$$

En notación matricial:

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon \quad (6.3)$$

donde: - $\mathbf{Y}$ es un vector $n \times 1$ de observaciones - $\mathbf{X}$ es una matriz $n \times (k + 1)$ de diseño - β es un vector $(k + 1) \times 1$ de parámetros - ε es un vector $n \times 1$ de errores

6.1.3.2. Interpretación de coeficientes parciales (ceteris paribus)

En regresión múltiple, β_j representa el **efecto marginal** de X_j sobre Y , manteniendo **constantes** todas las demás variables explicativas. Esto es crucial para el control de variables confusoras (Wooldridge 2015).

Tabla 6.2: Modelo de regresión múltiple: Determinantes del salario

term	estimate	std.error	statistic	p.value	conf.low	conf.high
(Intercept)	20692.466	3405.062	6.077	0.000	13976.989	27407.943
edad	997.822	156.220	6.387	0.000	689.725	1305.920
experiencia	297.930	164.206	1.814	0.071	-25.917	621.778
educacionSecundaria	7319.872	833.352	8.784	0.000	5676.331	8963.412
educacionUniversidad	14576.768	918.700	15.867	0.000	12764.903	16388.632

Tabla 6.3: Comparación de modelos: Simple vs. Múltiple

model	r.squared	adj.r.squared	AIC	BIC	p.value
simple	0.6923	0.6907	4163.086	4172.980	0
multiple	0.8825	0.8801	3976.526	3996.316	0

6.1.3.3. Linealidad en parámetros

El modelo es lineal en los **parámetros** β_j , no necesariamente en las **variables**. Podemos incluir: - Transformaciones: $\log(X)$, $\sqrt{X}$, X^2 - Interacciones: $X_1 \times X_2$ - Variables dummy para categorías

Interpretación de educación: Controlando por edad y experiencia, tener educación universitaria se asocia con un incremento promedio de 7320 dólares en el salario comparado con educación primaria.

6.2. Supuestos del MCRL y Estimación MCO

6.2.1. Supuestos del Modelo Clásico de Regresión Lineal (MCRL)


6.2.1.1. Supuestos fundamentales

1. **Linealidad en parámetros:** El modelo está correctamente especificado
2. **Exogeneidad estricta:** $E(\varepsilon_i|X_i) = 0$ para todo i
3. **Homoscedasticidad:** $\text{Var}(\varepsilon_i|X_i) = \sigma^2$ (varianza constante)
4. **No autocorrelación:** $\text{Cov}(\varepsilon_i, \varepsilon_j|X) = 0$ para $i \neq j$
5. **No multicolinealidad perfecta:** $\text{rank}(\mathbf{X}) = k + 1$
6. **Normalidad** (para muestras pequeñas): $\varepsilon_i \sim N(0, \sigma^2)$


6.2.1.2. Implicaciones de violaciones

Supuesto violado	Efecto en MCO	Inferencia afectada
Exogeneidad	Sesgo e inconsistencia	Sí
Homoscedasticidad	Ineficiencia	Errores estándar
No autocorrelación	Ineficiencia	Errores estándar
Multicolinealidad	Alta varianza	Significancia
Normalidad	-	Pruebas t/F (muestras pequeñas)

6.2.1.3. Verificación práctica de supuestos



```
## `geom_smooth()` using method = 'loess' and formula = 'y ~ x'
```



Prueba de Breusch-Pagan (Homoscedasticidad):

```
##
## studentized Breusch-Pagan test
##
## data: modelo_multiple
## BP = 8.8749, df = 4, p-value = 0.0643
```

##

Prueba de Shapiro-Wilk (Normalidad):

```
##
## Shapiro-Wilk normality test
##
## data: residuals(modelo_multiple)
## W = 0.99557, p-value = 0.8302
```

Tabla 6.4: Verificación: MCO manual vs. función lm()

	Coefficiente	MCO_manual	lm_function	Diferencia
(Intercept)	(Intercept)	20692.4663	20692.4663	0
edad	edad	997.8225	997.8225	0
experiencia	experiencia	297.9304	297.9304	0
educacionSecundaria	educacionSecundaria	7319.8716	7319.8716	0
educacionUniversidad	educacionUniversidad	14576.7678	14576.7678	0

6.2.2. Estimación por Mínimos Cuadrados Ordinarios (MCO)

6.2.2.1. Derivación del estimador

El estimador MCO minimiza la suma de cuadrados de residuos:

$$\min_{\beta} \sum_{i=1}^n (Y_i - \mathbf{x}_i^T \beta)^2 \quad (6.4)$$

La solución analítica es:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \quad (6.5)$$

6.2.2.2. Propiedades estadísticas

Bajo los supuestos del MCRL: - **Insesgadez:**

$$E[\hat{\beta} | \mathbf{X}] = \beta \quad (6.6)$$

- **Eficiencia:** BLUE (Best Linear Unbiased Estimator) por el teorema de Gauss-Markov - **Consistencia:**

$$\text{plim}_{n \rightarrow \infty} \hat{\beta} = \beta \quad (6.7)$$

- **Normalidad asintótica:**

$$\hat{\beta} \xrightarrow{d} N(\beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}) \quad (6.8)$$

6.2.2.3. Estimación de σ^2

El estimador insesgado de la varianza del error es:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{\varepsilon}_i^2}{n - k - 1} = \frac{\text{SCR}}{n - k - 1} \quad (6.9)$$

donde SCR es la suma de cuadrados de los residuos y $n - k - 1$ son los grados de libertad.

Tabla 6.5: Pruebas t individuales para coeficientes

term	estimate	std.error	statistic	p.value	significancia
(Intercept)	20692.4663	3405.0619	6.0770	0.0000	***
edad	997.8225	156.2199	6.3873	0.0000	***
experiencia	297.9304	164.2059	1.8144	0.0712	.
educacionSecundaria	7319.8716	833.3520	8.7836	0.0000	***
educacionUniversidad	14576.7678	918.7004	15.8667	0.0000	***

Note:

Códigos de significancia: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

6.3. Inferencia Estadística en Regresión

6.3.1. Distribución de los estimadores

Bajo normalidad de los errores:

$$\hat{\beta}_j \sim N(\beta_j, \sigma^2[(\mathbf{X}^T \mathbf{X})^{-1}]_{jj}) \quad (6.10)$$

El estadístico t estandarizado:

$$t = \frac{\hat{\beta}_j - \beta_j}{\text{se}(\hat{\beta}_j)} \sim t_{n-k-1} \quad (6.11)$$

6.3.2. Pruebas de hipótesis

6.3.2.1. Prueba t para coeficientes individuales

$$H_0 : \beta_j = 0 \quad \text{vs.} \quad H_1 : \beta_j \neq 0 \quad (6.12)$$

6.3.2.2. Prueba F para significancia conjunta

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0 \quad (6.13)$$

$$F = \frac{(\text{SCT} - \text{SCR})/k}{\text{SCR}/(n-k-1)} \sim F_{k,n-k-1} \quad (6.14)$$

Estadístico F: 366.157

Tabla 6.6: Análisis de Varianza (ANOVA)

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
edad	1	29583539075	29583539075	1212.4683	0.0000
experiencia	1	2991060	2991060	0.1226	0.7266
educacion	2	6149552056	3074776028	126.0183	0.0000
Residuals	195	4757889304	24399432	NA	NA

p-valor: 1.85e-89

Conclusión: Rechazamos H0: al menos un coeficiente es significativo

6.3.3. Intervalos de confianza y predicción

6.3.3.1. Intervalos de confianza para coeficientes

$$\hat{\beta}_j \pm t_{\alpha/2, n-k-1} \times \text{se}(\hat{\beta}_j) \quad (6.15)$$

6.3.3.2. Intervalos de predicción

Para una nueva observación X_0 :

- Intervalo de confianza para $E(Y|X_0)$:

$$\hat{Y}_0 \pm t_{\alpha/2, n-k-1} \times \text{se}(\hat{Y}_0) \quad (6.16)$$

- Intervalo de predicción para una nueva Y_0 :

$$\hat{Y}_0 \pm t_{\alpha/2, n-k-1} \times \sqrt{\text{se}^2(\hat{Y}_0) + \hat{\sigma}^2} \quad (6.17)$$

\begin{table} \caption{Intervalos de confianza al 95 % para coeficientes}

	2.5 %	97.5 %
(Intercept)	13976.99	27407.94
edad	689.72	1305.92
experiencia	-25.92	621.78
educacionSecundaria	5676.33	8963.41
educacionUniversidad	12764.90	16388.63

\end{table}

\begin{table} \caption{Predicciones con intervalos de predicción al 95 \%}

edad	experiencia	educacion	fit	lwr	upr	amplitud_intervalo
30	5	Universidad	66694	56796	76592	19796
40	15	Universidad	79651	69780	89522	19742
50	25	Secundaria	85352	75460	95243	19783

\end{table}

6.4. Medidas de Bondad de Ajuste

6.4.1. Coeficiente de determinación R^2

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT} \quad (6.18)$$

donde: - SCE = Suma de cuadrados explicada - SCR = Suma de cuadrados de residuos - SCT = Suma de cuadrados total

6.4.2. R^2 ajustado

Penaliza por el número de variables:

$$\bar{R}^2 = 1 - \frac{SCR/(n - k - 1)}{SCT/(n - 1)} \quad (6.19)$$

6.4.3. Limitaciones del R^2

Como advierte Harrell Jr (2015): - No indica causalidad - Puede ser alto con modelo mal especificado - No es apropiado para comparar modelos no anidados - En predicción, preferir validación cruzada

6.5. Diagnóstico del Modelo: Análisis de R

6.5.1. Tipos de Residuos

1. Residuos ordinarios:

$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i \quad (6.20)$$

Tabla 6.7: Métricas de bondad de ajuste

Métrica	Valor
R ²	0.8825
R ² ajustado	0.8801
Error estándar residual	4939.5782
AIC	3976.5259
BIC	3996.3158

Tabla 6.8: Descomposición de la varianza

Componente	Valor	Porcentaje
Suma Total de Cuadrados (SCT)	40493971495	100.00
Suma Explicada (SCE)	35736082191	88.25
Suma de Residuos (SCR)	4757889304	11.75
Verificación: SCE + SCR	40493971495	NA

2. Residuos estandarizados:

$$\frac{\hat{\varepsilon}_i}{\hat{\sigma}} \quad (6.21)$$

3. Residuos estudentizados:


$$\frac{\hat{\varepsilon}_i}{\hat{\sigma}_i \sqrt{1 - h_{ii}}} \quad (6.22)$$

donde h_{ii} es el leverage de la observación i .

6.5.2. Gráficos de diagnósticos esenciales


Posterior Predictive Check

Model-predicted lines should resemble observed data




Linearity

Reference line should be flat and horizontal




Homogeneity of Variance

Reference line should be flat and horizontal




Influential Observations

Points should be inside the contour lines



Collinearity

High collinearity (VIF) may inflate parameter uncertainty



Normality of Residuals

Data should fall along the line






Tabla 6.9: Observaciones potencialmente influyentes

obs_number	leverage	cooks_d	.std.resid
116	0.0456	0.0734	-2.7712
196	0.0430	0.0540	2.4496
91	0.0236	0.0413	-2.9211
72	0.1130	0.0334	-1.1458
165	0.0261	0.0287	-2.3121
49	0.0192	0.0255	2.5514
136	0.0278	0.0245	-2.0720
113	0.0328	0.0234	1.8572
130	0.0243	0.0233	2.1602
163	0.0251	0.0217	2.0500

```
## `geom_smooth()` using formula = 'y ~ x'
## `geom_smooth()` using formula = 'y ~ x'
## `geom_smooth()` using formula = 'y ~ x'
```



6.5.3. Detección de observaciones influyentes



6.6. Violaciones de los Supuestos y Remedios

6.6.1. Heteroscedasticidad

La heteroscedasticidad ocurre cuando $\text{Var}(\varepsilon_i|X_i) \neq \sigma^2$.

6.6.1.1. Detección

```
##
## studentized Breusch-Pagan test
##
## data: modelo_multiple
## BP = 8.8749, df = 4, p-value = 0.0643

##
## studentized Breusch-Pagan test
##
## data: modelo_multiple
## BP = 0.37302, df = 2, p-value = 0.8299
```

Tabla 6.10: Comparación de errores estándar: Clásicos vs. Robustos

Coficiente	Clásicos	HC0 (White)	HC1	HC2	HC3
(Intercept)	3405.0619	3535.9458	3580.9915	3618.3737	3704.4184
edad	156.2199	164.5280	166.6239	168.1914	172.0031
experiencia	164.2059	170.0246	172.1906	173.5876	177.2852
educacionSecundaria	833.3520	869.4293	880.5053	881.1232	893.0479
educacionUniversidad	918.7004	889.1385	900.4656	901.4941	914.0654

Tabla 6.11: Comparación de tests de heteroscedasticidad

Modelo	BP_estadistico	p_valor	Conclusion
Original	8.8749	0.0643	Homoscedasticidad
Log-log	20.2938	0.0004	Heteroscedasticidad presente

```
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 0.3056539, Df = 1, p = 0.58036
```

6.6.1.2. Remedios

1. Errores estándar robustos (HC):

```
##
## t test of coefficients:
##
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)    20692.47    3580.99   5.7784 2.946e-08 ***
## edad           997.82     166.62   5.9885 1.002e-08 ***
## experiencia     297.93     172.19   1.7302  0.08517 .
## educacionSecundaria 7319.87    880.51   8.3133 1.570e-14 ***
## educacionUniversidad 14576.77    900.47  16.1880 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

2. Transformaciones de variables:

6.6.2. Multicolinealidad

Problema cuando las variables explicativas están altamente correlacionadas.

Tabla 6.12: Diagnóstico de Multicolinealidad (VIF)

	Variable	VIF	Tolerancia	Interpretacion
edad	edad	17.706	0.056	Multicolinealidad severa
experiencia	experiencia	17.683	0.057	Multicolinealidad severa
educacion	educacion	1.011	0.989	Sin problema

Tabla 6.13: Efecto del centrado en VIF

Modelo	VIF_edad	VIF_experiencia
Original	NA	NA
Centrado	NA	NA

6.6.2.1. Detección mediante VIF

6.6.2.2. Remedios para multicolinealidad


```
## Cargando paquete requerido: princomp
```

```
## Warning in library(package, lib.loc = lib.loc, character.only = TRUE, logical.return = TRUE, :  
## paquete llamado 'princomp'
```

6.6.3. Autocorrelación (Series de Tiempo)

Relevante cuando las observaciones tienen orden temporal.

```
##  
## Durbin-Watson test  
##  
## data: modelo_tiempo  
## DW = 1.7104, p-value = 0.05872  
## alternative hypothesis: true autocorrelation is greater than 0  
  
##  
## Breusch-Godfrey test for serial correlation of order up to 2  
##  
## data: modelo_tiempo  
## LM test = 2.6754, df = 2, p-value = 0.2624
```



6.7. Selección de Variables y Extensiones del Modelo

6.7.1. Selección de Variables y Modelos

6.7.1.1. Criterios de información

Los criterios AIC y BIC penalizan la complejidad del modelo:

▪ **AIC:**

$$AIC = n \ln(\hat{\sigma}^2) + 2k \quad (6.23)$$

▪ **BIC:**

$$BIC = n \ln(\hat{\sigma}^2) + k \ln(n) \quad (6.24)$$

Menor valor indica mejor ajuste penalizado.

Tabla 6.14: Comparación de modelos candidatos

Modelo	r.squared	adj.r.squared	AIC	BIC	df	logLik	delta_AIC	delta_BIC
Completo	0.883	0.880	3976.526	3996.316	4	-1982.263	0.000	0.000
Con interacción	0.883	0.879	3978.519	4001.607	5	-1982.259	1.993	5.290
Solo edad	0.731	0.729	4136.509	4146.404	1	-2065.254	159.983	150.083
Edad + Experiencia	0.731	0.728	4138.454	4151.647	2	-2065.227	161.928	155.333
Solo experiencia	0.692	0.691	4163.086	4172.981	1	-2078.543	186.560	176.660
Solo educacion	0.173	0.165	4362.788	4375.981	2	-2177.394	386.262	379.662

Tabla 6.15: Comparación de métodos de selección automática

Método	Fórmula	AIC
Forward	salario ~ edad + educacion + experiencia	3976.526
Backward	salario ~ edad + I(edad^2) + experiencia + I(experiencia^2) + educacion + edad:experiencia	3979.519
Both	salario ~ edad + I(edad^2) + experiencia + I(experiencia^2) + educacion + edad:experiencia	3979.519

Tabla 6.16: Comparación final: Criterios de información vs. Validación cruzada

Modelo	r.squared	AIC	BIC	RMSE CV
Con interacción	0.8825	3978.519	4001.607	4974.539
Completo	0.8825	3976.526	3996.316	4987.617
Solo edad	0.7306	4136.509	4146.404	7350.871
Edad + Experiencia	0.7306	4138.454	4151.647	7496.063
Solo experiencia	0.6923	4163.086	4172.980	7906.562
Solo educacion	0.1731	4362.788	4375.981	12967.654

Tabla 6.17: Comparación de sistemas de contrastes

Contraste	term	estimate	std.error	p.value
Treatment	educacionSecundaria	7319.8716	833.3520	0.0000
Treatment	educacionUniversidad	14576.7678	918.7004	0.0000
Sum	educacion1	-7298.8798	510.1630	0.0000
Sum	educacion2	20.9918	473.0623	0.9647

Tabla 6.18: Modelo con término de interacción: edad $\times$ educación

term	estimate	std.error	statistic	p.value
(Intercept)	21708.081	3729.121	5.821	0.000
edad	971.042	161.416	6.016	0.000
educacion2	6179.504	3013.293	2.051	0.042
educacion3	11194.238	3842.483	2.913	0.004
experiencia	291.350	165.127	1.764	0.079
edad:educacion2	32.864	83.434	0.394	0.694
edad:educacion3	95.930	105.793	0.907	0.366

6.7.1.2. Selección automática de variables

6.7.1.3. Validación cruzada para selección

6.7.2. Extensiones del Modelo Lineal

6.7.2.1. Variables categóricas y contrastes

```
## [1] "Primaria"    "Secundaria"  "Universidad"
```


```
##           Secundaria Universidad
## Primaria           0           0
## Secundaria         1           0
## Universidad         0           1
```

6.7.2.2. Términos de interacción

```
## `geom_smooth()` using formula = 'y ~ x'
```


Tabla 6.19: Comparación: Modelo lineal vs. polinomial

Modelo	R_squared	AIC	BIC
Lineal	0.8825	3976.526	3996.316
Polinomial orden 2	0.8826	3980.393	4006.780



```
## Analysis of Variance Table
##
## Model 1: salario ~ edad + experiencia + educacion
## Model 2: salario ~ edad * educacion + experiencia
##   Res.Df      RSS Df Sum of Sq    F Pr(>F)
## 1     195 4757889304
## 2     193 4737705612  2  20183692 0.4111 0.6635
```

6.7.2.3. Transformaciones no lineales



6.7.2.4. Transformaciones logarítmicas

```
##      salario      edad      experiencia
## Min.   : 27244   Min.   :11.91   Min.    : 0.000
## 1st Qu.: 56271   1st Qu.:28.74   1st Qu.: 6.965
## Median : 65958   Median :34.41   Median :12.380
## Mean   : 66599   Mean   :34.91   Mean    :13.255
## 3rd Qu.: 76128   3rd Qu.:40.68   3rd Qu.:18.973
## Max.   :109101   Max.   :67.41   Max.    :44.629
```

6.8. Evaluación Predictiva y Validación

6.8.1. División entrenamiento-prueba

```
##
##      Primaria  Secundaria  Universidad
## 0.2977099    0.4122137    0.2900763
##
```

Tabla 6.20: Interpretación de coeficientes en modelos logarítmicos

Modelo	Especificación	Interpretación
Lineal	$Y = \beta_0 + \beta_1 X$	Cambio absoluto en Y por unidad de X
Log-lin	$\ln(Y) = \beta_0 + \beta_1 X$	Cambio porcentual en Y por unidad de X ($100 \times \beta_1$ %)
Lin-log	$Y = \beta_0 + \beta_1 \ln(X)$	Cambio absoluto en Y por 1 % de cambio en X ($\beta_1 / 100$)
Log-log	$\ln(Y) = \beta_0 + \beta_1 \ln(X)$	Elasticidad: cambio porcentual en Y por 1 % de cambio en X

Tabla 6.21: R^2 en escala original para modelos logarítmicos

Modelo	$R^2_{\text{original scale}}$
Lineal	0.6791
Log-lin	0.6585
Lin-log	0.6793
Log-log	0.6809

```
##      Primaria  Secundaria  Universidad
## 0.2962963    0.4074074    0.2962963
```

6.8.2. Métricas de evaluación predictiva

```
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
```

```
## Warning: contrasts dropped from factor educacion
```

Tabla 6.22: Métricas predictivas en conjunto de prueba

Modelo	RMSE	MAE	MAPE	R^2_{test}
Lineal simple	8050.289	6298.384	10.007	0.600
Múltiple	4903.629	3639.305	5.906	0.854
Polinomial	4842.077	3572.242	5.820	0.857
Con interacciones	4888.792	3636.790	5.897	0.855

[illegible]

Tabla 6.23: Resultados de validación cruzada 10-fold

Modelo	RMSE_mean	RMSE_sd	MAE_mean	MAE_sd
Simple	7931.286	802.867	6521.248	589.677
Multiple	4966.527	989.093	4040.838	851.957
Polinomial	4988.095	947.505	4026.032	823.031
Interacciones	5011.097	1021.473	4079.546	874.988

```
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
```

6.9. Modelos GLM y Técnicas de Regularización

6.9.1. Introducción a Modelos Lineales Generalizados (GLM)

6.9.1.1. Extensión más allá de la normalidad

Los GLM extienden la regresión lineal a variables respuesta no normales mediante:

1. **Función de enlace** $g(\mu)$: conecta la media $\mu = E(Y|X)$ con el predictor lineal
2. **Familia exponencial**: especifica la distribución de Y

6.9.1.2. Regresión logística binaria

Para variable respuesta binaria $Y \in \{0, 1\}$:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k \quad (6.25)$$

Tabla 6.24: Regresión logística: Odds ratios y intervalos de confianza

term	estimate	std.error	statistic	p.value	conf.low	conf.high
(Intercept)	0.022	2.317	-1.649	0.099	0.000	1.867
edad	1.149	0.103	1.353	0.176	0.943	1.414
experiencia	1.022	0.102	0.210	0.834	0.835	1.248
educacion2	0.858	0.456	-0.336	0.737	0.345	2.086
educacion3	2.651	0.575	1.695	0.090	0.886	8.692

donde $p = P(Y = 1|X)$.

Interpretación de Odds Ratios:

- Edad: Por cada año adicional, las odds de alta paga se multiplican por 1.149

- Universidad vs Primaria: Las odds se multiplican por 2.651

Setting levels: control = No, case = Si

Setting direction: controls < cases

##

Área bajo la curva ROC: 0.806




Tabla 6.25: Comparación de coeficientes: MCO vs. Métodos regularizados

Variable	MCO	Ridge	LASSO	ElasticNet
edad	932.8464	696.4409	937.1110	861.1700
experiencia	366.6502	551.9123	355.8014	420.7625
educacionPrimaria	NA	-7041.3959	-7395.3385	-7277.9026
educacionSecundaria	NA	28.7848	0.0000	0.0000
educacionUniversidad	NA	6996.8680	7215.5683	7124.1962

6.9.2. Técnicas de Regularización: Ridge y LASSO

6.9.2.1. Introducción a la regularización

Cuando $p \approx n$ o $p > n$, o cuando hay multicolinealidad severa, MCO puede ser inestable. Las técnicas de regularización añaden penalizaciones:


- **Ridge:**


$$\min_{\beta} \|Y - X\beta\|_2^2 + \lambda \|\beta\|_2^2 \quad (6.26)$$

- **LASSO:**

$$\min_{\beta} \|Y - X\beta\|_2^2 + \lambda \|\beta\|_1 \quad (6.27)$$

- **Elastic Net:** Combinación de ambas





6.10. Práctica y Material Complementario

6.10.1. Análisis de Regresión en la Práctica: Flujo de Trabajo Completo

6.10.1.1. Metodología reproducible paso a paso

```
## === RESUMEN EXPLORATORIO ===
## Dimensiones: 185 5
## Variable objetivo: salario
##
## Variables numéricas:
##      salario      edad      experiencia
## Min.   : 35595   Min.   :20.56   Min.   : 0.06241
## 1st Qu.: 57727   1st Qu.:30.16   1st Qu.: 8.03052
## Median : 68198   Median :35.41   Median :12.98361
## Mean   : 68336   Mean   :36.21   Mean   :14.32956
## 3rd Qu.: 76370   3rd Qu.:41.37   3rd Qu.:19.61531
## Max.   :109101   Max.   :67.41   Max.   :44.62903
##
## Variables categóricas:
## educacion : 55 76 54
## alta_paga  : 41 144
```

Tabla 6.26: Selección final de modelo basada en desempeño predictivo

Modelo	RMSE_test	MAE_test	R2_train	AIC_train	n_params
Básico	5050.008	3807.203	0.8658	2568.525	5
Completo	5074.355	3822.790	0.8672	2575.205	9
Con interacción	5083.885	3829.504	0.8662	2572.153	7
Con cuadrático	5125.627	3912.181	0.8664	2569.990	6

```
##
## No hay valores faltantes.

## Correlaciones altas (|r| > 0.8):
## edad - salario: 0.824
## experiencia - salario: 0.805
## salario - edad: 0.824
## experiencia - edad: 0.971
## salario - experiencia: 0.805
## edad - experiencia: 0.971

##
## === DIAGNÓSTICOS DEL MODELO ===
## R2 = 0.8825, R2 ajustado = 0.8801
## AIC = 3976.53, BIC = 3996.32
##
## Pruebas de supuestos:
## Normalidad (Shapiro-Wilk): p = 0.8302 (Aceptar normalidad)
## Homoscedasticidad (BP): p = 0.0643 (Aceptar homoscedasticidad)
## Multicolinealidad (VIF máximo): 17.71 (Problemática)
## Observaciones influyentes (Cook > 4/n): 10 de 185

## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
## Warning: contrasts dropped from factor educacion
```

6.10.1.2. Reporte automatizado de resultados

```
## === REPORTE EJECUTIVO DEL MODELO ===
##
## MODELO SELECCIONADO:
## salario ~ edad + experiencia + educacion
##
```

```
## MÉTRICAS DE AJUSTE:
## •  $R^2 = 86.3\%$  (86.3% de la varianza explicada)
## • Error estándar residual = $4961
## • Significancia global:  $p < 0.000$ 
##
## VARIABLES SIGNIFICATIVAS:
## • educacion3: $14785 [IC 95%: $12902, $16667]
## • educacion2: $7481 [IC 95%: $5748, $9215]
## • edad: $933 [IC 95%: $575, $1290]
## • experiencia: $367 [IC 95%: $6, $727]
##
## EVALUACIÓN DE SUPUESTOS:
##   Posible heteroscedasticidad detectada
##   Recomendación: Usar errores estándar robustos
##   Multicolinealidad detectada (VIF máximo = 17.87 )
##   Recomendación: Considerar eliminar variables redundantes
##   12 observaciones potencialmente influyentes detectadas
##   Recomendación: Revisar observaciones con Cook's D > 0.0216
##
## RECOMENDACIONES PARA USO:
## • Este modelo es apropiado para inferencia y predicción dentro del rango observado
## • Para predicciones fuera de muestra, validar supuestos en nuevos datos
## • Considerar intervalos de predicción para cuantificar incertidumbre
```

6.10.2. Buenas Prácticas y Lista de Verificación

6.10.2.1. Checklist para análisis de regresión

Antes del modelado: - ☐ Exploración exhaustiva de datos (EDA) - ☐
 Identificación de valores atípicos y faltantes - ☐ Análisis de correlaciones entre predictores - ☐ Definición clara del objetivo (inferencia vs. predicción)

Durante el modelado: - ☐ Especificación teórica justificada - ☐ Verificación de supuestos del MCRL - ☐ Evaluación de multicolinealidad ($VIF < 5$) - ☐
 Detección de observaciones influyentes - ☐ Comparación de modelos alternativos

Después del modelado: - ☐ Validación en datos independientes - ☐
 Interpretación sustantiva de coeficientes - ☐ Cuantificación de incertidumbre (intervalos) - ☐ Documentación del proceso analítico - ☐ Código reproducible disponible

6.10.2.2. Errores comunes a evitar**6.10.3. Ejercicios Propuestos y Actividades Prácticas****6.10.3.1. Ejercicio 1: Análisis completo con mtcars****6.10.3.2. Ejercicio 2: Variables categóricas con diamonds****6.10.3.3. Ejercicio 3: Series de tiempo y autocorrelación****6.10.3.4. Ejercicio 4: Proyecto integrador predictivo****6.10.4. Recursos Adicionales y Referencias****6.10.4.1. Lecturas recomendadas por nivel**

Nivel Introductorio: - James et al. (2013): Excelente balance teoría-práctica, muchos ejemplos en R - Bruce et al. (2020): Enfoque moderno para científicos de datos - Gelman et al. (2020): Pedagogía ejemplar, integra inferencia y predicción

Nivel Intermedio: - Harrell Jr (2015): Estrategias avanzadas de modelado, énfasis en validación - Kuhn and Johnson (2019): Ingeniería de características y selección de predictores - Fox (2015): Análisis aplicado con extensiones a GLM

Nivel Avanzado: - Hastie et al. (2009): Fundamentos matemáticos del aprendizaje estadístico - Gujarati and Porter (2009): Econometría con énfasis en interpretación causal - Wooldridge (2015): Métodos econométricos modernos

6.10.4.2. Recursos en línea especializados

1. **Hernández (2023)** - “Modelos de Regresión con R”: Tutorial interactivo en español con casos reales colombianos. Disponible en: https://fhernanb.github.io/libro_regresion/
2. **Fortou (2023)** - “Laboratorio de Análisis de Datos”: Implementaciones prácticas con tidyverse y énfasis en reproducibilidad. Disponible en: <https://bookdown.org/josefortou/lab-book/>
3. **Team (2023)** - “Computational Data Analysis for the Life Sciences”: Métodos estadísticos modernos con R y Python. Disponible en: <https://cdr-book.github.io/index.html>

6.10.4.3. Paquetes de R recomendados

6.10.4.4. Conjuntos de datos para práctica

6.10.5. Resumen y Conclusiones

6.10.5.1. Puntos clave del capítulo

1. **Fundamentos conceptuales:** La regresión modela dependencia asimétrica, diferente de correlación. El término de error es crucial para validez estadística.
2. **Metodología MCO:** Mejor estimador lineal insesgado (BLUE) bajo supuestos del MCRL. Propiedades óptimas requieren verificación cuidadosa de supuestos.
3. **Inferencia estadística:** Pruebas t individuales, pruebas F conjuntas, intervalos de confianza y predicción. Distinguir significancia estadística de relevancia práctica.
4. **Diagnósticos esenciales:** Análisis de residuos, detección de observaciones influyentes, evaluación de multicolinealidad. Los gráficos son tan importantes como las pruebas formales.
5. **Violaciones y remedios:** Heteroscedasticidad (errores robustos), autocorrelación (MCG), multicolinealidad (selección/regularización). Cada problema requiere enfoque específico.
6. **Extensiones prácticas:** Variables categóricas, transformaciones, interacciones, introducción a GLM. El modelo lineal es punto de partida, no límite.
7. **Validación predictiva:** División train/test, validación cruzada, métricas fuera de muestra. Esencial para uso predictivo del modelo.
8. **Reproducibilidad:** Código documentado, decisiones justificadas, flujo de trabajo sistemático. La ciencia de datos es colaborativa y acumulativa.

6.10.5.2. Perspectivas futuras

El análisis de regresión tradicional se extiende naturalmente hacia:

- **Machine Learning:** Random forests, gradient boosting, redes neuronales
- **Inferencia causal:** Variables instrumentales, discontinuidades, experimentos naturales
- **Big Data:** Métodos escalables, computación distribuida, streaming

- **Bayesiano:** Incorporación de información previa, cuantificación de incertidumbre

Sin embargo, los principios fundamentales del modelado estadístico—especificación cuidadosa, verificación de supuestos, validación rigurosa—permanecen constantes sin importar la complejidad del método.

“Far better an approximate answer to the right question than an exact answer to the wrong question.” — John Tukey

La regresión lineal, por su interpretabilidad y solidez teórica, seguirá siendo herramienta fundamental en el arsenal del analista de datos moderno.

Capítulo 7

Diseño y Análisis de Experimentos: Fundamentos, Modelación e Interpretación

Objetivo: *Que el alumnado sea capaz de comprender, diseñar y analizar experimentos, interpretando la variabilidad de los datos y el efecto de uno o múltiples factores mediante modelos de análisis de varianza y diseños experimentales, apoyándose en herramientas visuales y de simulación para la toma de decisiones.*

Contenido

7.1. Fundamentos del experimento y análisis de variación

7.1.1. El experimento y sus fines

7.1.2. Elementos del experimento: factores, niveles, tratamientos, variable respuesta

7.1.3. Diseño del experimento

7.1.4. Número de ensayos

7.1.5. Análisis de variaciones

7.1.6. Análisis de resultados

7.2. Análisis de varianza e interpretación de resultados

7.2.1. ANOVA de un factor

7.2.1.1. Idea de comparación de tratamientos

7.2.1.2. Descomposición de la variación

7.2.1.3. Interpretación del estadístico F

7.2.2. ANOVA de dos factores

7.2.2.1. Dos criterios de variación

7.2.2.2. Interpretación básica

7.2.3. Comparaciones múltiples

7.2.3.1. ¿Qué tratamientos son diferentes?

7.2.3.2. Interpretación

7.3. Diseño experimental multifactorial y control de variabilidad

7.3.1. Bloques experimentales

7.3.1.1. Control de fuentes de variación

7.3.1.2. Concepto de bloques completos e incompletos

7.3.2. Cuadrados latinos

7.3.2.1. Control de dos fuentes de variación

covarianza ya que consideramos que requiere base fuerte en regresión, aumenta carga matemática y no es esencial para el objetivo del curso.

Capítulo 8

Inferencia Estadística No Paramétrica: Métodos y Aplicaciones

Objetivo: *El objetivo de este capítulo es familiarizar a los estudiantes de ingeniería con la inferencia no paramétrica. Este enfoque consta de una colección de procedimientos que les permitirá realizar análisis estadístico sin la necesidad de suponer distribuciones de probabilidad específicas para los datos.*

En particular, se busca que los alumnos aprendan a realizar pruebas no paramétricas en situaciones reales donde las técnicas paramétricas no sean factibles. Asimismo, se espera que adquieran la capacidad de interpretar los resultados de manera crítica y los relacionen con su campo profesional.

Contenido

8.1. Introducción a la inferencia no paramétrica

8.1.1. Diferencia entre métodos paramétricos y no paramétricos.

8.1.2. Ventajas y limitaciones.

8.1.3. Situaciones en las que se recomienda su uso.

8.2. Pruebas de hipótesis para una muestra

8.2.1. Prueba de los signos.

8.2.2. Prueba de Wilcoxon para una muestra.

8.3. Pruebas de hipótesis para dos muestras

8.3.1. Prueba de Mann-Whitney U (Wilcoxon de rangos sumados).

8.3.2. Prueba de los signos para pares apareados.

8.3.3. Prueba de Wilcoxon para pares apareados.

8.4. Extensión a más de dos muestras

8.4.1. Prueba de Kruskal-Wallis.

8.4.2. Prueba de Friedman para diseños con bloques.

8.5. Medidas de asociación no paramétricas

8.5.1. Coeficiente de correlación de rangos de Spearman.

8.5.2. Tau de Kendall.

8.6. Aplicaciones prácticas en ingeniería

8.6.1. Control de calidad y confiabilidad.

8.6.2. Comparación de procesos o materiales.

8.6.3. Ejemplos con datos reales (tiempos de respuesta, resistencia de materiales, rendimiento de equipos).

8.7. Implementación computacional

8.7.1. Ejemplos de aplicación en software estadístico (R, Python, SPSS y/o Excel).

Media.

Fortou, José. 2023. “Laboratorio de Análisis de Datos.” <https://bookdown.org/josefortou/lab-book/>.

Fox, John. 2015. *Applied Regression Analysis and Generalized Linear Models*. 3rd ed. SAGE Publications.

Gelman, Andrew, Jennifer Hill, and Aki Vehtari. 2020. *Regression and Other Stories*. Cambridge University Press.

Gujarati, Damodar N, and Dawn C Porter. 2009. *Basic Econometrics*. 5th ed. McGraw-Hill/Irwin.

Harrell Jr, Frank E. 2015. *Regression Modeling Strategies: With Applications to Linear Models, Logistic and Ordinal Regression, and Survival Analysis*. 2nd ed. Springer.

Hastie, Trevor, Robert Tibshirani, and Jerome Friedman. 2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd ed. Springer.

Hernández, Freddy. 2023. “Modelos de Regresión Con r.” https://fhernanb.github.io/libro_regresion/.

James, Gareth, Daniela Witten, Trevor Hastie, and Robert Tibshirani. 2013. *An Introduction to Statistical Learning: With Applications in r*. Springer.

Kuhn, Max, and Kjell Johnson. 2019. *Feature Engineering and Selection: A Practical Approach for Predictive Models*. CRC Press.

Team, CDR Book. 2023. “Computational Data Analysis for the Life Sciences.” <https://cdr-book.github.io/index.html>.

Wooldridge, Jeffrey M. 2015. *Introductory Econometrics: A Modern Approach*. 6th ed. Cengage Learning.